



UNIVERSIDADE PRESBITERIANA MACKENZIE  
FACULDADE DE COMPUTAÇÃO E INFORMÁTICA  
TECNOLOGIA EM CIÊNCIAS DE DADOS

## **PROJETO APLICADO II**

**Projeto Sentinela: Automação do Controle de Acesso Veicular  
em Condomínios.**

**PROFESSOR:** FELIPE ALBINO DOS SANTOS

**GRUPO:**

ALINE CORRÊA – 10414773 – 10414773@mackenzista.com.br

ISAQUE PIMENTEL – 10415608 – 10415608@mackenzista.com.br

MAIKI SOARES – 10415481 – 10415481@mackenzista.com.br

VANESSA CORDEIRO – 10415118 – 10415118@mackenzista.com.br

São Paulo  
2024

## SUMÁRIO

1.	DEFINIÇÃO DE BIBLIOTECAS PYTHON .....	3
2.	DEFINIÇÃO DA BASE DE DADOS E ANÁLISE EXPLORATÓRIA .....	4
3.	TRATAMENTO DA BASE DE DADOS.....	8
4.	MÉTODOS ANALÍTICOS.....	8
5.	DESCRIÇÃO DA METODOLOGIA Da ACURÁCIA .....	10

## 1. DEFINIÇÃO DE BIBLIOTECAS PYTHON

Para desenvolver um sistema de reconhecimento de placas veiculares, existem algumas bibliotecas Python que podem ser úteis nessa tarefa:

- **OpenCV**: biblioteca de processamento de imagem, usada no pré-processamento de imagens, detecção de contorno e segmentação.
- **TensorFlow**: framework de aprendizado de máquina e deep learning usado no treinamento de modelo de reconhecimento de imagens.
- **PyTesseract**: interface para biblioteca OCR Tesseract, útil para reconhecer os caracteres das placas.
- **Matplotlib e Seaborn**: bibliotecas de visualização de dados e análise de resultados.
- **Numpy e Pandas**: bibliotecas de manipulação e análise de dados padrão em Python.

Os scripts Python que foram utilizados no projeto podem ser encontrados no repositório Github abaixo:

<https://github.com/isaque-pimentel/projeto-aplicado-II>

Segue por exemplo uma extração do README do Projeto Aplicado II:



**Figura 1** – Captura de tela do README do Projeto Aplicado II no Github.  
Fonte: Elaboração própria (2024).

## 2. DEFINIÇÃO DA BASE DE DADOS

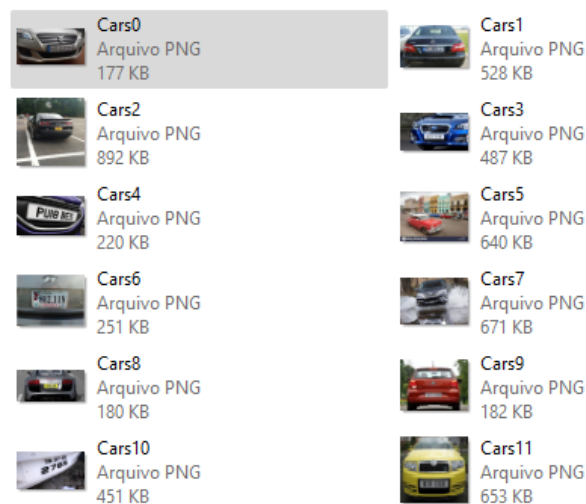
Para implementar esse sistema, foi feita uma busca na internet por uma base de dados de imagens completa. A base de dados escolhida foi um *dataset* fornecido pelo Kaggle, intitulado *Car License Plate*, que pode ser encontrado no endereço abaixo:

<https://www.kaggle.com/datasets/andrewmvd/car-plate-detection/data>

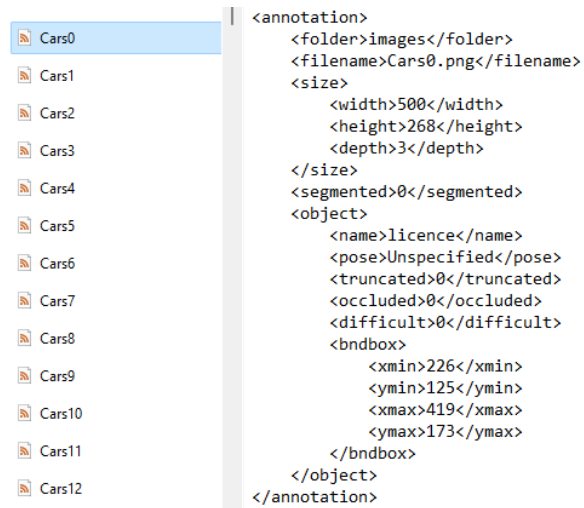
Esse *dataset* é uma coleção abrangente de 433 imagens contendo veículos automotivos de marcas variadas com placas veiculares de identificação de diversos países. Este conjunto de dados é uma fonte valiosa para projetos de reconhecimento de placas veiculares sobre o qual criaremos nosso modelo de detecção para localizar onde se encontram as placas dentro das imagens.

### Descrição da Base de Dados

A base de dados contém imagens de veículos automotivos capturadas de diversas perspectivas e condições de iluminação. Cada imagem é um arquivo PNG que está acompanhada de anotações, no formato XML, indicando a localização das placas de identificação dos veículos.



**Figura 2** – Amostra das imagens de veículos automotivos no formato PNG.  
Fonte: Elaboração própria (2024).



**Figura 3** – Amostra das anotações da localização das placas no formato XML.  
Fonte: Elaboração própria (2024).

### 3. ANÁLISE EXPLORATÓRIA

#### Proposta da Análise Exploratória

Para esse *dataset*, a proposta de análise exploratória é a seguinte:

- Exploração das imagens: iniciar a análise exploratória examinando de maneira aleatória algumas imagens do *dataset* para entender a diversidade dos veículos e condições de captura.
- Distribuição das classes de veículos: verificar a distribuição dos tipos de veículos presentes no *dataset* para entender se há um desequilíbrio entre as classes.
- Tamanho das imagens: analisar o tamanho médio das imagens para determinar a resolução mais comum e os potenciais desafios de pré-processamento.
- Visualização das anotações: visualizar algumas imagens com suas respectivas anotações para verificar a qualidade e precisão das marcações das placas de identificação.
- Análise de iluminação: avaliar a distribuição das condições de iluminação nas imagens para entender como isso pode afetar a detecção das placas.
- Pré-processamento das imagens: Explorar técnicas de pré-processamento, como ajuste de contraste e equalização de histograma, para melhorar a qualidade das imagens e facilitar a detecção das placas.

Com essa análise, seremos capazes de obter insights para o desenvolvimento do sistema de reconhecimento de placas veiculares a partir dessa base *Car License Plate*.

#### Compreensão da Base de Dados


Segue abaixo alguns exemplos das imagens de veículos encontrados na nossa base de dados:



**Figura 4** – Amostra Cars0 e Cars1 dentro do base de dados.  
Fonte: *Car License Plate Dataset*

A identificação da localização das placas foi um processo manual realizado previamente e a posição das placas foi salva em arquivos de anotação no formato XML. É necessário transformar o formato da posição das placas (aqui chamada de *labels*) do formato XML para um formato que possa ser lido pelo modelo de detecção (no caso, algo do tipo `np.array`). Foi realizado um *parsing* dos dados no XML e uma conversão para um único arquivo `csv`. Esse procedimento foi salvo no arquivo `parse_annotations.py`.

Antes de realizar a Análise Exploratória, podemos realizar uma verificação se o quadro da etiqueta foi corretamente assinalado para uma determinada imagem. O usuário poderia escolher uma imagem para adicionar o quadro da etiqueta em amarelo. Esse procedimento foi salvo no arquivo `verify_image.py`. Por exemplo, no arquivo `Car108.png` temos um veículo com uma etiqueta corretamente assinalada sobre a placa, enquanto no arquivo `Car126.png` temos um veículo com uma etiqueta bem maior que a própria placa.



**Figura 5** – Amostra `Cars108.png` e `Cars126.png` com o quadro da etiqueta em amarelo.  
Fonte: *Car License Plate Dataset*

## 4. TRATAMENTO DA BASE DE DADOS

Para o tratamento da base de dados em um projeto de Controle de Acesso Veicular em Condomínios, é importante considerar a segurança e organização das informações contidas na base de dados.

- Coleta de dados: garantir que os dados dos veículos sejam coletados de forma correta, incluindo informações como placa do veículo, nome do proprietário, número do documento de identificação, entre outros.
- Armazenamento seguro: implementar medidas de segurança para proteger a base de dados, como criptografia e acesso restrito apenas a pessoas autorizadas.
- Atualização constante: manter a base de dados sempre atualizada, incluindo informações sobre novos veículos e alteração de proprietários.
- Controle de acesso: estabelecer políticas de controle de acesso à base de dados, garantindo que apenas pessoas autorizadas tenham permissão para acessar ou modificar as informações contidas nela.

As diretrizes acima para o tratamento da base de dados garantem a eficácia e segurança do projeto de Controle de Acesso Veicular em Condomínios a ser desenvolvido, protegendo a privacidade e integridade das informações dos veículos.

## 5. METODOS ANALÍTICOS

O problema de reconhecimento de placas veiculares é um problema bastante conhecido e desafiador na área de *computer vision*. Para alcançar esse objetivo, é preciso empregar uma variedade de métodos e algoritmos. Vamos apenas descrevermos algumas das bases teóricas desses métodos:

### **Processamento de imagem**

O processamento de imagens é essencial para a detecção e pré-processamento das imagens de veículos. No campo de *computer vision*, existem diferentes técnicas como filtragem, segmentação e transformações de imagem, que são aplicadas para simplificar ou aumentar a qualidade das imagens ou destacar as características relevantes, como as placas dos veículos.




Como exemplo de transformação, temos a equalização de histogramas. Primeiramente, um histograma de uma imagem preto e branco mostra a intensidade do cinza para cada pixel da imagem. Assim, essa operação visa a uniformizar o nível de cinza numa imagem visando melhorar o contraste. Um segundo exemplo de transformação é a binarização, cujo processo visa transformar a intensidade do pixel em 1 (branco) ou em 0 (preto).

### Aprendizado de Máquina

Certamente, o *Machine Learning* desempenha um papel ímpar no reconhecimento de placas veiculares. Por exemplo, os algoritmos de aprendizado supervisionado (que é o problema de detecção de imagem), como as redes neurais convolucionais (CNNs), são muito utilizados para treinar modelos capazes de extrair informações e reconhecer padrões em imagens em geral.

Como exemplo de algoritmo de ML, temos a regressão linear, onde a partir de preditores  $x_i$  é feita a predição de uma variável de saída  $y$ . Uma melhoria considerável no modelo anterior, é o perceptron, um classificador linear binário. A partir dos dados de entradas  $x$ , de pesos  $w$  e de uma função de ativação  $f$ , podemos produzir uma variável de saída  $y$  binária. É sabido que o Perceptron só converge se os dados forem linearmente separáveis, ou seja, se existir um hiperplano que separe os dados. Uma melhoria desse modelo, é o Multilayer Perceptron (MLP), que é composta por uma camada de neurônios de entrada, uma camada de neurônios de saída e pelo menos uma camada escondida. Esse modelo pode ser visto como a ideia de base das redes neurais convolucionais (CNN), que são aplicadas para imagens.



**Figura 6** – Perceptron com 5 entradas, é um classificador linear binário.  
Fonte: w3schools.com (*Internet*)

## **Detecção de Objetos**

A detecção de objetos é uma técnica que permite identificar a presença e a localização de determinados objetos em imagens. Por exemplo, podemos detectar a presença de uma placa ou da face de um ser humano. Existem métodos como o algoritmo de Viola-Jones, e algoritmos baseados em redes neurais, como YOLO (You Only Look Once), que são frequentemente empregados para a detecção eficiente de objetos, inclusive o de placas de veículos.

Por exemplo, o YOLO se destaca por rápido e eficiente. A seguir, explicamos o motivo. Esse método divide uma imagem em uma grade de células, onde cada célula representa a presença de objetos dentro dela. Depois, são feitas previsões sobre cada uma das caixas e a confiança de cada uma das caixas conter um objeto. Finalmente, usa-se uma técnica chamada *non-max suppression* para combinar várias caixas que representam um mesmo objeto, removendo as caixas de baixa confiança.

## **Reconhecimento de Caracteres**

O reconhecimento óptico de caracteres (OCR) é crucial para extrair os caracteres alfanuméricos das placas de identificação dos veículos. Existem por exemplo, técnicas como segmentação de caracteres (que é a divisão em pequenos retângulos contendo possivelmente um caractere), extração de características (é a determinação se é uma letra com traços retos ou número com traços curvos) e classificação de caracteres são aplicadas para identificar os caracteres presentes nas placas.

Enfim, essas são algumas das ferramentas possíveis de serem utilizadas no desenvolvimento do nosso sistema de reconhecimento de placas veiculares.

## **6. DESCRIÇÃO DA METODOLOGIA DA ACURÁCIA**

O reconhecimento de placas veiculares é um problema que envolve diferentes tarefas: (1) a detecção precisa da placa e (2) a extração de caracteres das placas presentes nas imagens de veículos. Para avaliar os modelos desenvolvidos, é importante utilizar uma métrica de desempenho adequada, com destaque para a acurácia.

### **O que é a acurácia?**

É uma métrica comumente usada para medir a precisão de um modelo de classificação (por exemplo, classificar veículos entre diferentes modelos). Essa métrica representa a proporção de exemplos classificados corretamente em relação ao total de exemplos.

$$\text{Acurácia} = \frac{\text{Numero de previsões corretas}}{\text{Numero total de previsões}}$$

onde podemos expandir em previsões totalmente corretas ou parcialmente corretas com 1 caractere errado por exemplo.

No entanto, o problema de reconhecimento de placas veiculares não é um problema de classificação clássico, onde alocamos as imagens em diferentes classes. Além disso, temos 3 grandes tarefas: a detecção, segmentação e a extração de caracteres.

### **Detecção de placas**

O objetivo dessa tarefa é localizar a região da placa. A acurácia da detecção será a proporção de placas veiculares detectadas corretamente em relação ao número total de placas. Para se dizer que uma placa foi classificada corretamente é necessário que a razão entre interseção entre a região verdadeira da placa  $A_{true}$  e a estimação da região da placa  $A_{est}$  pela união entre elas seja por exemplo maior que 70%:

$$\frac{A_{true} \cap A_{est}}{A_{true} \cup A_{est}} > 0.7$$

### **Segmentação**

Nessa tarefa, o objetivo é a segmentação da região de cada um dos caracteres numa imagem de placa veicular. Assim, a acurácia da segmentação será a proporção de placas com todos os caracteres segmentados em relação ao número total de placas.

$$\text{Acurácia} = \frac{\text{Numero de placas corretamente segmentadas}}{\text{Numero total de placas}}$$

### **Classificação de caracteres**

Enquanto na etapa da extração de caracteres, podemos utilizar métodos conhecidos de OCR para classificar as letras e o dígitos das placas. usar a classificação de cada caractere. Mais uma vez, a acurácia da classificação de

caracteres será a proporção de caracteres corretamente classificados em relação ao número total de caracteres:

$$Acurácia = \frac{\textit{Numero de carecteres corretas}}{\textit{Numero total de caracteres}}$$

onde podemos é possível expandir os resultados por cada um dos dígitos e por cada uma das letras.